

KI erkennt Netzwerkangriffe

Einführung in Data Mining mit Orange

ALP Dillingen · Cisco Academy · 90 Minuten



Das Problem

Euer Netzwerk ist durch eine **Cisco NGFW** (Next-Generation Firewall) oder eine **ASA mit IPS-Modul** geschützt. Diese Geräte analysieren jeden Paket-Header gegen eine Signatur-Datenbank – Deep Packet Inspection (DPI).

Schwachstelle bei DDoS: Tausende Flows/Sekunde Appliance-CPU auf 100 % Alarmer häufen sich Administratoren ignorieren sie (Alert Fatigue) echter Angriff bleibt unbemerkt.

Idee: Ein einfaches ML-Modell filtert böartigen Traffic vor der DPI-Stufe – anhand statistischer Flow-Merkmale, ohne Payload-Inspektion.

Übung 1

Welche 2 Flow-Merkmale könnten bei einem DDoS-Angriff auffällig sein?
(Tipp: Paketgröße? Antwortverhalten des Servers?)

Übung 2

Was seht ihr im Scatter Plot? Beschreibt in einem Satz, warum Down/Up Ratio=0 bei DDoS physikalisch sinnvoll ist.

Regelbasiert vs. Machine Learning

Regelbasiert	Experten schreiben Regeln: if SYN > 1000 → BLOCK. Neue Angriffe erfordern neue Regeln.
Machine Learning	Modell lernt Regeln aus Daten: Beispiele mit bekannten Labels Muster erkennen. Neue Muster: neue Trainingsdaten genügen.

Datensatz: CICIDS2017

10 000 Flows aus einem simulierten On-Premise-Netz (Firewall · Switch · 12 Hosts):
5 000 BENIGN (Montag) + 5 000 DDoS (Freitag, LOIT).

Feature	BENIGN	DDoS
Packet Length Mean	60 B	834 B
Down/Up Ratio	1,0	0,0
Flow Duration	31 ms	1893 ms
Flow Packets/s	119	2,5
SYN Flag Count	0,06	0,0

Phase 2 – Daten erkunden

Workflow: workshop_workflow_phase1.ows

1. **File:** workshop_ids.tab öffnen
2. **Data Table:** Spalten und Werte ansehen – was bedeutet jede Zeile?
3. **Scatter Plot:** X = Packet Length Mean, Y = Down/Up Ratio, Farbe = Label

Phase 3 – Entscheidungsbaum

Workflow: workshop_workflow.ows

4. **Data Sampler:** 70 % Training / 30 % Test
5. **Tree:** Modell trainieren (Standardeinstellungen)
6. **Tree Viewer:** Regeln lesen; Knoten anklicken
Scatter Plot leuchtet auf

Ein Entscheidungsbaum stellt **Ja/Nein-Fragen** zu den Features. Die Regeln sind menschenlesbar – das ist Explainable AI: KI, die wir erklären und verteidigen können.

Übung 3

a) Lest die erste Verzweigung im Tree Viewer laut vor. Ergibt sie für euch als Netzwerker Sinn?

b) Klickt einen Knoten an. Welche Datenpunkte leuchten im Scatter Plot auf?

Phase 4 – Modellbewertung

7. **Test and Score:** Accuracy, Precision, Recall (10-fache Kreuzvalidierung)
8. **Confusion Matrix:** FP auswählen Scatter Plot zeigt Grenzfälle

	Pred. DDoS	Pred. BENIGN
Ist DDoS	TP	FN
Ist BENIGN	FP !	TN

Übung 4

Accuracy = 98 %, 10 000 Flows pro Stunde.

a) Wie viele Fehlentscheidungen pro Stunde?

b) Was ist in eurem Schulnetz schlimmer – FP oder FN?

Phase 5 – Modellvergleich

9. **Random Forest + kNN** mit Test and Score verbinden und vergleichen

Modell	Accuracy	Erklärbar?
Entscheidungsbaum	~98 %	Ja
Random Forest	~99 %	Nein
kNN	~96 %	Bedingt

Random Forest: Viele Bäume stimmen ab – wie ein Komitee.

kNN: Klasse der nächsten Nachbarn in den Trainingsdaten.

Übung 5

Welches Modell würdet ihr als Vorfilter vor einer NGFW einsetzen? Begründet mit einem Argument für Genauigkeit oder Erklärbarkeit.

Glossar

Flow	Verbindungszusammenfassung (kein Payload)
Feature Label	Messbares Merkmal eines Flows
Training	Bekannte Klasse: BENIGN oder DDoS
Accuracy	Modell lernt aus 70 % der Daten
FP	Anteil richtig klassifizierter Flows
FN	Fehlalarm – BENIGN fälschlich als DDoS
Alert Fatigue	Übersehener Angriff – DDoS als BENIGN
Explainable AI	Admins ignorieren Alarme (zu viele FP)
	KI mit lesbaren, verteidigbaren Regeln

Datensatz: CICIDS2017 · Univ. of New Brunswick · cicresearch.ca
Tool: Orange · orangedatamining.com
Materialien: workshop_ids.tab · workshop_workflow.ows · workshop_workflow_phase1.ows