

KI erkennt Netzwerkangriffe

Einführung in Data Mining mit Orange

ALP Dillingen · Cisco Academy · 90 Minuten



Das Problem

Unser Netzwerk ist durch eine **Cisco NGFW** (Next-Generation Firewall) oder eine **ASA mit IPS-Modul** geschützt. Diese Geräte analysieren jeden Paket-Header gegen eine Signatur-Datenbank – Deep Packet Inspection (DPI).

Schwachstelle bei DDoS: Tausende Flows/Sekunde → Appliance-CPU auf 100 % → Alarme häufen sich → Administratoren ignorieren sie (Alert Fatigue) → echter Angriff bleibt unbemerkt.

Idee: Ein einfaches ML-Modell filtert böartigen Traffic vor der DPI-Stufe – anhand statistischer Flow-Merkmale, ohne Payload-Inspektion.

Übung 1

Welche 2 Flow-Merkmale könnten bei einem DDoS-Angriff auffällig sein?
(Tipp: Paketgröße? Antwortverhalten des Servers?)

Übung 2

Was sehen wir im Scatter Plot? Beschreibt in einem Satz, warum Down/Up Ratio=0 bei DDoS physikalisch sinnvoll ist.

Regelbasiert vs. Machine Learning

Regelbasiert	Experten schreiben Regeln: if SYN > 1000 → BLOCK. Neue Angriffe erfordern neue Regeln.
Machine Learning	Modell lernt Regeln aus Daten: Beispiele mit bekannten Labels → Muster erkennen. Neue Muster: neue Trainingsdaten genügen.

Datensatz: CICIDS2017

10 000 Flows aus einem simulierten On-Premise-Netz (Firewall · Switch · 12 Hosts):
5 000 BENIGN (Montag) + 5 000 DDoS (Freitag, LOIC).

Feature	BENIGN	DDoS
Packet Length Mean	60 B	834 B
Down/Up Ratio	1,0	0,0
Flow Duration	31 ms	1893 ms
Flow Packets/s	119	2,5
SYN Flag Count	0,06	0,0

Phase 2 – Daten erkunden

Workflow: workshop_workflow_phase1.ows

1. **File:** workshop_ids.tab öffnen
2. **Data Table:** Spalten und Werte ansehen – was bedeutet jede Zeile?
3. **Scatter Plot:** X = Packet Length Mean, Y = Down/Up Ratio, Farbe = Label

Phase 3 – Entscheidungsbaum

Workflow: `workshop_workflow.ows`

4. **Data Sampler:** 70 % Training / 30 % Test
5. **Tree:** Modell trainieren (Standardeinstellungen)
6. **Tree Viewer:** Regeln lesen; Knoten anklicken → Scatter Plot leuchtet auf

Ein Entscheidungsbaum stellt **Ja/Nein-Fragen** zu den Features. Die Regeln sind menschenlesbar – das ist Explainable AI: KI, die wir erklären und verteidigen können.

Übung 3

a) Lest die erste Verzweigung im Tree Viewer laut vor. Ergibt sie für uns als Netzwerker Sinn?

b) Klickt einen Knoten an. Welche Datenpunkte leuchten im Scatter Plot auf?

Phase 4 – Modellbewertung

7. **Test and Score:** Accuracy, Precision, Recall (10-fache Kreuzvalidierung)
8. **Confusion Matrix:** FP auswählen → Scatter Plot zeigt Grenzfälle

	Pred. DDoS	Pred. BENIGN
Ist DDoS	TP	FN
Ist BENIGN	FP !	TN

Übung 4

Accuracy = 98 %, 10 000 Flows pro Stunde.

a) Wie viele Fehlentscheidungen pro Stunde?

b) Was ist in unserem Schulnetz schlimmer – FP oder FN?

Phase 5 – Modellvergleich

9. **Random Forest + kNN** mit Test and Score verbinden und vergleichen

Entscheidungsbaum – Flowchart-Logik: Das Modell findet automatisch die besten Ja/Nein-Fragen, die BENIGN und DDoS trennen. Jede Regel ist lesbar – wie ein Troubleshooting-Leitfaden, aber aus Daten generiert.

Random Forest – Komitee-Entscheid: 100 unabhängige Bäume, jeder auf einem anderen Zufallsausschnitt der Trainingsdaten trainiert. Die Mehrheit entscheidet. Genauer, aber die Regeln sind nicht mehr lesbar.

kNN – Ähnlichkeits-Suche: Für jeden neuen Flow: suche die k ähnlichsten bekannten Flows und nimm ihre Mehrheitsklasse. Kein trainiertes Modell – daher zu langsam für Leitungsgeschwindigkeit.

Modell	Acc.	Lesbar?	Vorfilter?
Entscheidungsbaum	~98 %	Ja	Ja
Random Forest	~99 %	Nein	Ja
kNN	~96 %	Bedingt	Nein

Übung 5

Welches Modell würden wir als Vorfilter vor einer NGFW einsetzen? Begründet mit einem Argument für Genauigkeit oder Erklärbarkeit.

Glossar

Flow	Verbindungszusammenfassung (kein Payload)
Feature Label	Messbares Merkmal eines Flows Bekannte Klasse: BENIGN oder DDoS
Training Accuracy FP	Modell lernt aus 70 % der Daten Anteil richtig klassifizierter Flows Fehlalarm – BENIGN fälschlich als DDoS
FN	Übersehener Angriff – DDoS als BENIGN
Alert Fatigue	Admins ignorieren Alarme (zu viele FP)
Explainable AI	KI mit lesbaren, verteidigbaren Regeln
Entscheidungsbaum	Flowchart-Logik; Regeln aus Daten generiert
Random Forest	100 Bäume stimmen per Mehrheit ab
kNN	Klasse der k ähnlichsten Trainingsbeispiele

Datensatz: CICIDS2017 · Univ. of New Brunswick · cicresearch.ca

Tool: Orange · orangedatamining.com

Materialien: `workshop_ids.tab` · `workshop_workflow.ows` · `workshop_workflow_phase1.ows`