

KI erkennt Netzwerkangriffe

Einführung in Data Mining mit Orange



Florian Reichl

Akademie für Lehrerfortbildung und Personalführung
Dillingen

2026

Einstieg

Agenda

- | | | | |
|---|--------|--|--------|
| 1. Einstieg | 10 min | 4. Modellbewertung | 20 min |
| Cisco NGFW, DDoS, ML als Vorfilter | | Accuracy, Confusion Matrix, Alert
Fatigue | |
| 2. Daten erkunden | 15 min | 5. Modellvergleich | 10 min |
| Data Table, Scatter Plot | | Random Forest, kNN, Erklärbarkeit | |
| 3. Entscheidungsbaum | 25 min | 6. Abschluss | 10 min |
| Tree trainieren, Tree Viewer, Regeln
lesen | | Transfer, Materialien, Feedback | |


Cisco NGFW schützt unser Netzwerk

On-Premise-Unternehmensnetzwerk

- Cisco NGFW / ASA mit IPS-Modul
- Switch, Web-Server, 10 Clients

Deep Packet Inspection (DPI)

Jedes Paket wird gegen eine **Signatur-Datenbank** geprüft – Header und Payload.



Das Problem: DDoS überlastet die Firewall

Angriffsszenario

Tausende Flows pro Sekunde treffen gleichzeitig ein – ein DDoS-Angriff.

Die Überlastungskette:

1. DDoS flutet das Netz mit Flows
2. NGFW-CPU steigt auf 100 % – DPI bricht zusammen
3. Alarme häufen sich – Admins können nicht mehr priorisieren
4. **Alert Fatigue:** echte Angriffe bleiben unbemerkt

Die Idee: ML als Vorfilter

Heute: Jeder Flow → NGFW → DPI

Mit Vorfilter:

Jeder Flow → **ML-Modell**

→ eindeutig BENIGN → durchlassen

→ eindeutig DDoS → blockieren

→ unklar → NGFW → DPI

Nur noch 10–20 % des Traffics erreicht die DPI-Stufe.

Entscheidend: kein Payload

Das ML-Modell analysiert **keine Payloads** – nur statistische Flow-Metriken:

Paketgröße · Antwortverhalten ·
Durchsatz

Schnell genug für
Leitungsgeschwindigkeit.

**Ein einfacher Entscheidungsbaum mit
2–3 Regeln
erreicht ca. 98 % Genauigkeit.**


Lernziele

Nach diesem Workshop können Sie ...


1. erläutern, was **maschinelles Lernen** ist und wie es sich von **vom Menschen vorgenommener Regelkonfiguration (Signaturpflege)** unterscheidet
2. erklären, wie **ML-Vorfilterung** Cisco-Geräte bei DDoS entlasten kann
3. beschreiben, wie ein **Entscheidungsbaum** Netzwerktraffic klassifiziert
4. beurteilen, was **Accuracy, False Positives** und **False Negatives** im IDS-Kontext bedeuten
5. einschätzen, was den Unterschied zwischen einem **interpretierbaren** und einem **Black-Box-Modell** ausmacht
6. **Orange Data Mining** für einen einfachen Klassifikations-Workflow nutzen
7. das heutige Vorgehen den **sechs Phasen von CRISP-DM** zuordnen

Maschinelles Lernen

Regelkonfiguration



Machine Learning



Regelbasiert vs. maschinell lernen

Regelkonfiguration (Signaturpflege)

Experte schreibt Regeln per Hand:

```
if SYN_count > 1000 → BLOCK  
if payload contains  
"exploit" → ALERT
```

Problem: Neue Angriffe erfordern neue Regeln.

Cisco-IPS: täglich neue Signaturen nötig.

Machine Learning

Algorithmus lernt Regeln aus Daten:

Beispiele mit bekannten Labels →
Modell erkennt Muster selbst →
Regeln entstehen automatisch

Neue Angriffe: neue Trainingsdaten
genügen.

Kein manuelles Signatur-Update.

Der Unterschied im Kern

Regelkonfiguration (Signaturpflege)

1. Experte analysiert Angriffsmuster
2. Experte schreibt Regel: `if SYN > 1000`
→ BLOCK
3. Regel wird deployed
4. Neuer Angriff → zurück zu Schritt 1

Machine Learning

1. Trainingsdaten sammeln (Flows + Labels)
2. Algorithmus analysiert Muster **selbst**
3. Modell generiert Regeln automatisch
4. Neuer Angriff → neue Daten genügen

Die Kernformel


Regelkonfiguration: Mensch → Regeln → Ergebnisse

ML: Daten + Ergebnisse → Maschine → Regeln

Unser Prozessrahmen: CRISP-DM

CRISP-DM ist der meistgenutzte Prozessrahmen für Data-Mining-Projekte – industrie- und werkzeugneutral seit 1996.

- | | | |
|---|---------------|--|
| 1 | Business Und. | Wie funktioniert DDoS?
Was lässt sich messen? |
| 2 | Data Und. | Datensatz lesen: Was trennt BENIGN von DDoS? |
| 3 | Data Prep. | Daten für Orange aufbereiten (vorbereitet) |
| 4 | Modeling | Entscheidungsbaum aus Trainingsdaten lernen |
| 5 | Evaluation | Entlastet der Filter die NGFW spürbar? |



Daten erkunden

CRISP-DM · Phase 2: Data Understanding

Im Workshop

Welche Daten liegen vor, was bedeuten sie, und wie unterscheiden sich BENIGN von DDoS?

Der Datensatz: CICIDS2017

Quelle

Canadian Institute for Cybersecurity,
Univ. of New Brunswick

Unser Subset

- Montag (BENIGN) + Freitag (DDoS)
- 10 000 Flows, 11 Features
- Datei: workshop_ids.tab

Ausgewählte Features

Flow Duration	Flow-Dauer
Flow Packets/s	Pakete/Sekunde
Flow Bytes/s	Bytes/Sekunde
SYN Flag Count	SYN-Pakete
Packet Length Mean	Ø Paketgröße
Down/Up Ratio	Antwort-
Quote	
Label	BENIGN / DDoS

Daten erkunden: Data Table

Datentabelle — Orange

Info

10000 instances (no missing data)
11 features
Target with 2 values
No meta attributes.

Variables

☒ Show variable labels (if present)
☒ Visualize numeric values
☒ Color by instance classes

Selection

☒ Select full rows

☒ Send Automatically


	Label	Total Fwd Packets	Backward Packets	Flow Bytes/s	Flow Packets/s	Flow Duration	FIN Flag Count	SYN Flag Count	ACK Flag Count	Packet Length	Mean Down/Up Ratio	Average Packet Size
1	DDoS	5	0	2.59456	0.432426	1.15627e+07	0	0	1	6.00000	0	7.20000
2	BENIGN	2	2	16743.6	128.304	31176	0	0	0	111.40000	1	139.25000
3	DDoS	9	5	124.121	0.148992	9.3965e+07	0	0	1	777.93300	0	833.50000
4	DDoS	5	0	5.75937	0.959894	5.20891e+06	0	0	1	6.00000	0	7.20000
5	BENIGN	2	2	1.25275e+06	21978	182	0	0	0	55.40000	1	69.25000
6	DDoS	5	0	8.39166	1.39861	3.57498e+06	0	0	1	6.00000	0	7.20000
7	DDoS	3	6	18676	14.4489	622884	0	0	0	1163.30000	2	1292.56000
8	DDoS	3	5	16869.8	11.6014	689574	0	0	0	1292.56000	1	1454.12000
9	DDoS	4	0	2.37701	0.396168	1.00967e+07	0	0	1	6.00000	0	7.50000
10	BENIGN	2	2	8320.87	130.014	30766	0	0	0	61.20000	1	76.50000
11	DDoS	4	0	4.93129	0.821881	4.86688e+06	0	0	1	6.00000	0	7.50000
12	DDoS	3	5	315385	217.002	36866	0	0	0	1291.89000	1	1453.38000
13	BENIGN	2	2	733728	11834.3	338	0	0	0	55.40000	1	69.25000
14	DDoS	3	5	6162.46	4.23792	1.88772e+06	0	0	0	1292.56000	1	1454.12000
15	BENIGN	2	2	400853	4264.39	938	0	0	0	84.40000	1	105.50000
16	BENIGN	5	0	97.7787	16.8584	296588	0	0	1	4.83333	0	5.80000
17	BENIGN	1	1	0	22222.2	90	0	0	1	0.00000	1	0.00000
18	BENIGN	1	1	272727	45454.5	44	0	0	1	6.00000	1	9.00000
19	DDoS	5	0	3.15864	0.52644	9.49776e+06	0	0	1	6.00000	0	7.20000

Was sehen wir im Scatter Plot?

Einstellungen

- X-Achse: Packet Length Mean
- Y-Achse: Down/Up Ratio
- Farbe: Label

Beobachtung?



Zwischensicherung: Daten haben Struktur

Kernaussage

Daten haben eine Struktur – und diese Struktur ist für uns sichtbar.
Genau diese Struktur **lernt** ein KI-Modell.

Entscheidungsbaum

CRISP-DM · Phase 4: Modeling

Im Workshop

Aus Trainingsdaten Entscheidungsregeln lernen.

Phase 3: Data Preparation (vorbereitet)

`workshop_ids.tab` wurde vorab bereinigt und für Orange aufbereitet.

Was ist ein Entscheidungsbaum?

Kennen wir das?

Cisco-Troubleshooting-Leitfäden:

Link-LED aus? → Kabel prüfen.

Ping OK? → Layer-3-Problem.

**Das Modell findet diese Fragen selbst,
aus den Trainingsdaten.**

Beispiel aus unseren Daten

Flow Bytes/s > 45 000?

Ja → DDoS (99 %)


Nein → Down/Up Ratio >
0.1?

Ja → BENIGN (98 %)

Nein → DDoS (94 %)

70,% Training · 30,% Test

Der Entscheidungsbaum in Orange



Welche Frage steht ganz oben?

Der Algorithmus **probiert alle möglichen Fragen** aus – jedes Feature, jeder Schwellenwert.

Für jede Frage prüft er: Wie rein sind die entstehenden Gruppen?

Rein = fast nur eine Klasse

Die Frage mit den **reinsten Gruppen** kommt ganz oben in den Baum.

Schlechte Frage: SYN Flag Count > 0?

Ja: DDoS und BENIGN
gemischt

Nein: DDoS und BENIGN
gemischt

Gruppen kaum getrennt.

Gute Frage: Flow Bytes/s > 45 000?

Ja: 99 % DDoS

Nein: 95 % BENIGN

Gruppen fast rein. → Wird die erste Frage.

Ist das Magie?

KI erklärt

Ein Entscheidungsbaum ist ein KI-Modell, das wir **lesen und erklären** können.

Das ist wichtig: Im echten Einsatz müssen wir erklären können, warum das System einen Alarm auslöst.

Modellbewertung

CRISP-DM · Phase 5: Evaluation

Im Workshop

Entlastet der Filter die NGFW spürbar? Kann das Modell gutartigen und böartigen Traffic gut genug trennen?

Wie gut ist unser Modell?

Test and Score

- Cross-Validation: 10-fach
- Modell sieht nur Testdaten

Typisches Ergebnis

Metrik	Wert
Accuracy	~98 %
Precision	~97 %
Recall	~98 %


Denkanstoß

98 % Genauigkeit – ist das gut?

Bei 10 000 Flows = **200 falsche Entscheidungen.**

Was davon sind Fehllalarme?
Was davon sind übersehene Angriffe?

Die Confusion Matrix



	DDoS	BENIGN
DDoS	TP ✓	FN ✗
BENIGN	FP !	TN ✓

TP True Positive
FN False Negative
FP False Positive
TN True Negative

Accuracy, Precision und Recall

Metrik	Formel	IDS-Frage
Accuracy	$\frac{TP + TN}{\text{alle Flows}}$	Wie oft liegt das Modell richtig?
Precision	$\frac{TP}{TP + FP}$	Von allen DDoS-Alarmen: wie viele waren wirklich DDoS?
Recall	$\frac{TP}{TP + FN}$	Von allen echten Angriffen: wie viele wurden erkannt?

Die Spannung im IDS

Precision vs. Recall

Hohe Precision → wenige Fehllarme (weniger Alert Fatigue)

Hoher Recall → wenige übersehene Angriffe

Beides gleichzeitig zu maximieren ist nicht möglich.

Extrembeispiel

Modell klassifiziert **alles** als DDoS:

Recall = 100 % aber Precision $\approx$ 50 %

→ Jeder zweite Alarm ist ein Fehllarm.

Alert Fatigue – ein reales Problem

False Positive

- Fehllalarm im IDS
- Admins bearbeiten unnötige Tickets
- Admins ignorieren irgendwann Alarme
- **Echter Angriff wird übersehen**

False Negative

- Angriff nicht erkannt
- Kein Alarm ausgelöst
- **Angreifer operiert unbemerkt**

Was ist schlimmer in unserem Netzwerk?

Kernaussage

Kein Modell ist perfekt. Wir müssen entscheiden, ob wir lieber Fehllalarme oder übersehene Angriffe akzeptieren – das ist eine **fachliche**, keine technische Entscheidung.

Modellvergleich

CRISP-DM · Phase 5: Evaluation (Fortsetzung)

Im Workshop

Welches Modell ist gut genug – und erklärbar genug, um es vor Vorgesetzten und Schülern zu verteidigen?

Entscheidungsbaum – Flowchart-Logik

Accuracy	ca. 97–98 %
Regeln	lesbar, verteidigbar
Training	schnell
Vorfilter	Ja

Flow Bytes/s > 45 000?

Ja → **DDoS** (99 %)

Zwei Fragen, 98 % Genauigkeit.

- Regeln lesbar wie ein Troubleshooting-Leitfaden
- Jede Entscheidung nachvollziehbar
- Kann Vorgesetzten oder Schülern gezeigt werden

Explainable AI

Im echten Einsatz ist es wünschenswert, erklären zu können, **warum** das Modell blockt. Der Entscheidungsbaum ermöglicht das – Random Forest nicht.

Random Forest – das Komitee

Das Prinzip: Nicht ein Baum, sondern **100 unabhängige Bäume**.

1. Jeder Baum auf zufälligem Daten-Ausschnitt trainiert (Bootstrap)
2. Bei jeder Verzweigung: zufällige Feature-Auswahl
3. Alle 100 Bäume stimmen ab – **Mehrheit entscheidet**

„87 von 100 Bäumen sagen DDoS → DDoS“

Accuracy ca. 99 % – ein Prozentpunkt besser als Tree.

Ein Baum kann überanpassen – 100 Bäume gleichen Fehler aus.

Nachteil: Black Box


100 Bäume → keine lesbaren Regeln.
Wir sehen das Ergebnis, nicht den Weg.

k-Nearest Neighbors – Ähnlichkeitssuche

Das Prinzip: kNN trainiert gar nichts – es speichert alle 7 000 Trainings-Flows.

1. Neuer Flow kommt an
2. Abstand zu allen 7 000 bekannten Flows berechnen
3. 5 ähnlichste finden ($k=5$)
4. Mehrheitsklasse der 5 Nachbarn $\rightarrow$ Vorhersage

„4 von 5 Nachbarn DDoS $\rightarrow$ DDoS“



Abstand = euklidischer Abstand im Feature-Raum

Drei Modelle im Vergleich

Modell	Accuracy	Regeln lesbar?	Als Vorfilter?
Entscheidungsbaum	ca. 97–98,%	Ja – jede Regel nachvollziehbar	Ja – erklärbar
Random Forest	ca. 99,%	Nein – 100 Bäume, nicht lesbar	Ja – genauer
kNN	ca. 95–97,%	Bedingt – Nachbarn zeigbar	Nein – zu langsam [*]

^{*}kNN speichert alle Trainingsdaten – jede Vorhersage erfordert einen Vergleich mit allen 7,000 Beispielen.

Genauigkeit vs. Erklärbarkeit

Kernaussage

Die Wahl des Modells ist nicht nur eine technische Frage.

Im Unterricht und im echten Einsatz zählt:

Kann ich das Ergebnis erklären und verteidigen?

Entscheidungsbaum:

„Wir können zeigen, warum dieser Flow als DDoS gilt.“

Random Forest:

„87 von 100 Bäumen sagten DDoS – aber warum, kann ich nicht zeigen.“

Abschluss

CRISP-DM · Phase 6: Deployment

Im Workshop

Das ML-Regelwerk im Kundennetz einrichten und aktivieren – als Entlastung vor der Cisco NGFW.

Was haben wir gelernt?

1. **DPI überlastet bei DDoS** – Cisco NGFW braucht einen Vorfilter
2. **ML lernt Regeln aus Daten** – kein manuelles Signatur-Update nötig ($\neq$ Regelkonfiguration)
3. **Entscheidungsbaum = erklärbare KI** – Regeln lesbar, verteidigbar, einsetzbar
4. **Kein Modell ist perfekt** – False Positives und False Negatives sind unvermeidbar
5. **Die Wahl des Modells ist eine Fachentscheidung** – Genauigkeit vs. Erklärbarkeit

Transfer in den Unterricht

Orange ist kostenlos und sofort einsetzbar:

- Funktioniert mit jedem CSV – auch eigene Datensätze möglich
- Entscheidungsbaum + Confusion Matrix passt in eine **Doppelstunde**
- CICIDS2017 ist öffentlich zugänglich (cicresearch.ca)
- Das Netzwerkdiagramm passt direkt in das **Cisco-Curriculum**

Nächste Schritte:

- Mehrklassen-Klassifikation (Botnet, Port Scan, DDoS)
- Weitere Datensätze erkunden (UNSW-NB15)
- Unüberwachtes Lernen (Clustering ohne Labels)

Materialien

Datei	Inhalt
workshop_ids.tab	Datensatz (10 000 Flows, 11 Features)
workshop_workflow.ows	Vorgefertigter Orange-Workflow
workshop_workflow_phase1.ows	Nur Daten-Explorer (Phase 2)
Handout (A4)	Kurzanleitung + Diskussionsfragen

Orange Data Mining: orangedatamining.com

CICIDS2017: cicresearch.ca

Danke – und ein Wort zum Schluss

Was wir heute gebaut haben,
ist der Vorfilter vor unserer Cisco NGFW.

Cisco Secure Network Analytics macht dasselbe –
nur mit Millionen Flows pro Minute.

Feedback: Ein Wort, das diesen Workshop beschreibt.