

KI erkennt Netzwerkangriffe

Einführung in Data Mining mit Orange



Florian Reichl

Akademie für Lehrerfortbildung und Personalführung
Dillingen

2026

Einstieg

Agenda

Einstieg

Daten erkunden

Entscheidungsbaum

Modellbewertung

Modellvergleich


Cisco NGFW schützt euer Netzwerk

On-Premise-Unternehmensnetzwerk

- Cisco NGFW / ASA mit IPS-Modul
- Switch, Web-Server, 10 Clients

Deep Packet Inspection (DPI)

Jedes Paket wird gegen eine
Signatur-Datenbank geprüft –\nHeader und Payload.



Das Problem: DDoS überlastet die Firewall

Angriffsszenario

Tausende Flows pro Sekunde treffen gleichzeitig ein – ein DDoS-Angriff.

Die Überlastungskette:

1. DDoS flutet das Netz mit Flows
2. NGFW-CPU steigt auf 100 % – DPI bricht zusammen
3. Alarme häufen sich – Admins können nicht mehr priorisieren
4. **Alert Fatigue:** echte Angriffe bleiben unbemerkt

Die Idee: ML als Vorfilter

Heute:

Jeder Flow → NGFW → DPI

Mit Vorfilter:

Jeder Flow → **ML-Modell** \ →
eindeutig BENIGN → durchlassen\
→ eindeutig DDoS → blockieren\
→ unklar → NGFW → DPI

Nur noch 10–20 % des Traffics
erreicht die DPI-Stufe.

Entscheidend

Das ML-Modell analysiert **keine Payloads** – nur statistische Flow-Metriken:

Paketgröße · Antwortverhalten ·
Durchsatz

Das ist schnell genug für
Leitungsgeschwindigkeit.

Heute bauen wir genau das

Regelbasiert vs. maschinell lernen

Good Old-Fashioned AI

Experte schreibt Regeln per Hand:

```
if SYN_count > 1000 → BLOCK  
if payload contains  
"exploit" → ALERT
```

Problem: Neue Angriffe erfordern neue Regeln.

Cisco-IPS: täglich neue Signaturen nötig.

Machine Learning

Algorithmus lernt Regeln aus Daten:

Beispiele mit bekannten Labels →
Modell erkennt Muster selbst →
Regeln entstehen automatisch

Neue Angriffe: neue Trainingsdaten
genügen.

Kein manuelles Signatur-Update.

Der Unterschied im Kern

Lernziele

Nach diesem Workshop können Sie ...

1. erklären, wie **ML-Vorfilterung** Cisco-Geräte bei DDoS entlasten kann
2. beschreiben, wie ein **Entscheidungsbaum** Netzwerktraffic klassifiziert
3. beurteilen, was **Accuracy, False Positives** und **False Negatives** im IDS-Kontext bedeuten
4. einschätzen, was den Unterschied zwischen einem **interpretierbaren** und einem **Black-Box-Modell** ausmacht
5. **Orange Data Mining** für einen einfachen Klassifikations-Workflow nutzen

Daten erkunden

Der Datensatz: CICIDS2017

Quelle

Canadian Institute for Cybersecurity,
Univ. of New Brunswick

Unser Subset

- Montag (BENIGN) + Freitag (DDoS)
- 10 000 Flows, 11 Features
- Datei: workshop_ids.csv

Ausgewählte Features

Flow Duration	Flow-Dauer
Flow Packets/s	Pakete/Sekunde
Flow Bytes/s	Bytes/Sekunde
SYN Flag Count	SYN-Pakete
Packet Length Mean	Ø Paketgröße
Down/Up Ratio	Antwort-
Quote	
Label	BENIGN / DDoS

Daten erkunden: Data Table

Datentabelle — Orange

Info
10000 instances (no missing data)
11 features
Target with 2 values
No meta attributes.

Variables
☒ Show variable labels (if present)
☒ Visualize numeric values
☒ Color by instance classes

Selection
Clear Selection
☒ Select full rows
Restore Original Order
☒ Send Automatically


	Label	Total Fwd Packets	Backward Packets	Flow Bytes/s	Flow Packets/s	Flow Duration	FIN Flag Count	SYN Flag Count	ACK Flag Count	Packet Length	Min/Down/Up Ratio	Average Packet Size
1	DDoS	5	0	2.59456	0.432426	1.15627e+07	0	0	1	6.00000	0	7.20000
2	BENIGN	2	2	16743.6	128.304	31176	0	0	0	111.40000	1	139.25000
3	DDoS	9	5	124.121	0.148992	9.3965e+07	0	0	1	777.93300	0	833.50000
4	DDoS	5	0	5.75937	0.959894	5.20891e+06	0	0	1	6.00000	0	7.20000
5	BENIGN	2	2	1.25275e+06	21978	182	0	0	0	55.40000	1	69.25000
6	DDoS	5	0	8.39166	1.39861	3.57498e+06	0	0	1	6.00000	0	7.20000
7	DDoS	3	6	18676	14.4489	622884	0	0	0	1163.30000	2	1292.56000
8	DDoS	3	5	16869.8	11.6014	689574	0	0	0	1292.56000	1	1454.12000
9	DDoS	4	0	2.37701	0.396168	1.00967e+07	0	0	1	6.00000	0	7.50000
10	BENIGN	2	2	8320.87	130.014	30766	0	0	0	61.20000	1	76.50000
11	DDoS	4	0	4.93129	0.821881	4.86688e+06	0	0	1	6.00000	0	7.50000
12	DDoS	3	5	315385	217.002	36866	0	0	0	1291.89000	1	1453.38000
13	BENIGN	2	2	733728	11834.3	338	0	0	0	55.40000	1	69.25000
14	DDoS	3	5	6162.46	4.23792	1.88772e+06	0	0	0	1292.56000	1	1454.12000
15	BENIGN	2	2	400853	4264.39	938	0	0	0	84.40000	1	105.50000
16	BENIGN	5	0	97.7787	16.8584	296588	0	0	1	4.83333	0	5.80000
17	BENIGN	1	1	0	22222.2	90	0	0	1	0.00000	1	0.00000
18	BENIGN	1	1	272727	45454.5	44	0	0	1	6.00000	1	9.00000
19	DDoS	5	0	3.15864	0.52644	9.49776e+06	0	0	1	6.00000	0	7.20000

Was sehen wir im Scatter Plot?

Einstellungen

- X-Achse: Packet Length Mean
- Y-Achse: Down/Up Ratio
- Farbe: Label

Beobachtung?



Zwischensicherung: Daten haben Struktur

Kernaussage

Daten haben eine Struktur – und diese Struktur ist für uns sichtbar.
Genau diese Struktur **lernt** ein KI-Modell.

Entscheidungsbaum

Was ist ein Entscheidungsbaum?

Kennt ihr das?

Cisco-Troubleshooting-Leitfäden funktionieren genauso:

„Leuchtet die Link-LED? → Nein → Kabel prüfen.“ \ „Ping möglich? → Ja → Layer-3-Problem.“

Ein Entscheidungsbaum ist genau das –\ nur findet das Modell die Fragen\ selbst, aus den Trainingsdaten.

Beispiel aus unseren Daten

Flow Bytes/s > 45 000?

Ja → DDoS (99 %)


Nein → Down/Up Ratio > 0.1?

Ja → BENIGN (98 %)

Nein → DDoS (94 %)

Trainingsphase: Modell sieht 7,000 Flows mit\ bekannten Labels und findet die besten Fragen.\[4pt] Testphase: 3,000 neue Flows – kein Label bekannt.

Der Entscheidungsbaum in Orange



Ist das Magie?

KI erklärt

Ein Entscheidungsbaum ist ein KI-Modell, das wir **lesen und erklären** können.

Das ist wichtig: Im echten Einsatz müssen wir erklären können, warum das System einen Alarm auslöst.

Modellbewertung

Wie gut ist unser Modell?

Test and Score

- Cross-Validation: 10-fach
- Modell sieht nur Testdaten

Typisches Ergebnis

Metrik	Wert
Accuracy	~98 %
Precision	~97 %
Recall	~98 %


Denkanstoß

98 % Genauigkeit – ist das gut?

Bei 10 000 Flows = **200 falsche Entscheidungen.**

Was davon sind Fehllalarme?
Was davon sind übersehene Angriffe?

Die Confusion Matrix



	DDoS	BENIGN
DDoS	TP ✓	FN ✗
BENIGN	FP !	TN ✓

TP True Positive\ **FN** False Negative\ **FP** False Positive\ **TN** True Negative

Alert Fatigue – ein reales Problem

False Positive

- Fehllalarm im IDS
- Admins bearbeiten unnötige Tickets
- Admins ignorieren irgendwann Alarme
- **Echter Angriff wird übersehen**

False Negative

- Angriff nicht erkannt
- Kein Alarm ausgelöst
- **Angreifer operiert unbemerkt**

Was ist schlimmer in eurem Netzwerk?

Kernaussage

Kein Modell ist perfekt. Wir müssen entscheiden, ob wir lieber Fehllalarme oder übersehene Angriffe akzeptieren – das ist eine **fachliche**, keine technische Entscheidung.

Modellvergleich

Drei Modelle – drei Ideen

Entscheidungsbaum

Flowchart-Logik

Das Modell stellt Ja/Nein-Fragen zu den Messwerten. Die Regeln sind lesbar wie ein Troubleshooting-Leitfaden.

„Wenn Flow Bytes/s > 45 000
→ DDoS“

Random Forest

Komitee-Entscheid

100 unabhängige Bäume, jeder auf einem anderen Daten-Ausschnitt trainiert. Die Mehrheit entscheidet.

„87 von 100 Bäumen sagen DDoS → DDoS“

k-Nearest Neighbors

Ähnlichkeits-Suche

Kein Training nötig. Für jeden neuen Flow: Suche die 5 ähnlichsten bekannten Flows. Was sind die?

„4 von 5 Nachbarn sind DDoS → DDoS“

Drei Modelle im Vergleich

Modell	Accuracy	Regeln lesbar?	Als Vorfilter?
Entscheidungsbaum	ca. 97–98,%	Ja – jede Regel nachvollziehbar	Ja – erklärbar
Random Forest	ca. 99,%	Nein – 100 Bäume, nicht lesbar	Ja – genauer
kNN	ca. 95–97,%	Bedingt – Nachbarn zeigbar	Nein – zu langsam [*]

^{*}kNN speichert alle Trainingsdaten – jede Vorhersage erfordert einen Vergleich mit allen 7,000 Beispielen.

Genauigkeit vs. Erklärbarkeit

Kernaussage

Die Wahl des Modells ist nicht nur eine technische Frage.

Im Unterricht und im echten Einsatz zählt:

Kann ich das Ergebnis erklären und verteidigen?

Entscheidungsbaum:

„Ich kann euch zeigen, warum dieser Flow als DDoS gilt.“

Random Forest:

„87 von 100 Bäumen sagten DDoS – aber warum, kann ich nicht zeigen.“

Abschluss

Was haben wir gelernt?

1. **DPI überlastet bei DDoS** – Cisco NGFW braucht einen Vorfilter
2. **ML lernt Regeln aus Daten** – kein manuelles Signatur-Update nötig ($\neq$ GOFA)
3. **Entscheidungsbaum = erklärbare KI** – Regeln lesbar, verteidigbar, einsetzbar
4. **Kein Modell ist perfekt** – False Positives und False Negatives sind unvermeidbar
5. **Die Wahl des Modells ist eine Fachentscheidung** – Genauigkeit vs. Erklärbarkeit

Transfer in den Unterricht

Orange ist kostenlos und sofort einsetzbar:

- Funktioniert mit jedem CSV – auch eigene Datensätze möglich
- Entscheidungsbaum + Confusion Matrix passt in eine **Doppelstunde**
- CICIDS2017 ist öffentlich zugänglich (cicresearch.ca)
- Das Netzwerkdiagramm passt direkt in das **Cisco-Curriculum**

Nächste Schritte:

- Mehrklassen-Klassifikation (Botnet, Port Scan, DDoS)
- Weitere Datensätze erkunden (UNSW-NB15)
- Unüberwachtes Lernen (Clustering ohne Labels)

Materialien

Datei	Inhalt
workshop_ids.csv	Datensatz (10 000 Flows, 11 Features)
workshop_workflow.ows	Vorgefertigter Orange-Workflow
workshop_workflow_phase1.ows	Nur Daten-Explorer (Phase 2)
Handout (A4)	Kurzanleitung + Diskussionsfragen

Orange Data Mining: orangedatamining.com

CICIDS2017: cicresearch.ca

Danke – und ein Wort zum Schluss

Was ihr heute gebaut habt,
ist der Vorfilter vor eurer Cisco NGFW.

Cisco Secure Network Analytics macht dasselbe –
nur mit Millionen Flows pro Minute.

Feedback: Ein Wort, das diesen Workshop beschreibt.